

星云智服企业知识助手项目背景与业务需求

文档编号: XY-RAG-REQ-001

版本: 1.0

发布日期: 2026-06-18

适用范围: 客户服务中心、售后技术部、运营管理部、信息安全部

文档状态: 正式发布

1. 项目背景

星云智服是一家提供企业软件实施、设备运维和客户支持服务的虚构公司。随着产品线扩大，公司内部积累了产品手册、工单记录、标准操作流程、培训材料和服务公告。资料总量持续增长，但文档分散在共享盘、知识库和邮件附件中，文件命名不统一，同一制度还可能存在多个版本。客服人员处理咨询时，往往需要在多个目录中搜索关键词，再判断文档是否仍然有效。新员工熟悉资料通常需要四到六周。

公司决定建设“星云知识助手”，采用检索增强生成架构。系统先从受控知识库检索证据，再让大语言模型依据证据组织答案。项目不追求让模型记住全部内部知识，而是要求知识可更新、答案可追溯、权限可控制、错误可定位。

2. 业务目标

第一阶段服务对象为一线客服和售后工程师，核心目标包括：缩短资料查找时间；减少过期制度被误用；让回答附带文档名称和版本；在没有充分证据时明确说明无法确认；为后续评测和持续优化保留可分析日志。

系统上线后，常见问题的平均资料定位时间应从约五分钟降低到一分钟以内。对于已经纳入知识库的标准问题，检索命中率应达到预设基线。系统生成的答案不得绕过权限控制，也不得把不同客户的私有资料混合返回。

3. 首期业务场景

3.1 产品使用咨询

客服输入自然语言问题，例如“设备离线后先检查什么”“升级失败是否可以直接断电”。系统应检索产品手册、故障处理流程和最新公告，给出分步骤说明，并标注证据来源。如果新版公告与旧版手册冲突，应优先采用生效日期更晚、状态为“有效”的文档。

3.2 售后故障排查

售后工程师可按设备型号、软件版本和故障代码查询。型号、版本号、工单编号等精确字符串不能只依赖语义相似度，应结合关键词检索或元数据过滤。例如用户输入故障码

E-204，系统必须优先定位明确包含 E-204 的文档，而不是返回语义相近但代码不同的故障说明。

3.3 制度与流程查询

员工可能询问“重大故障多久内升级”“谁可以批准紧急变更”。系统需要依据正式制度回答。若制度要求因事件等级而不同，答案必须列出适用条件，不能只给一个脱离条件的时间值。

3.4 新员工培训

知识助手可用于解释术语和流程，但不能替代必修培训、考试或人工授权。涉及生产系统操作、客户数据导出和高风险变更时，系统只能提供制度说明，不能把普通员工描述为已经获得权限。

4. 非目标范围

第一阶段不接入个人聊天记录，不自动执行生产变更，不直接发送客户通知，不代替工单审批，不以模型回答作为合规判定的唯一依据。系统也不允许根据缺失信息猜测客户身份、合同等级或设备版本。

5. 用户角色与权限

系统定义四类角色。

普通客服可以访问公开产品资料、标准问答和通用流程。售后工程师可以额外访问故障手册和经脱敏的案例库。部门主管可以查看本部门制度、统计报表和高等级事件复盘。知识管理员负责文档发布、版本替换、下线和标注，不默认拥有生产操作权限。

权限控制必须在检索阶段生效。系统不能先检索全部文档，再依靠提示词要求模型“不要泄露”。每个文档块都应携带部门、密级、客户范围、有效状态等元数据，检索时根据用户身份添加过滤条件。

6. 回答要求

答案应优先使用简洁步骤。涉及制度时，应写明适用范围、关键条件和来源。涉及不确定信息时，应说明缺少什么。证据不足时，应回复“当前知识库没有足够依据”，并建议查询哪个部门或补充哪些字段。

每次回答最多展示五个主要来源。来源至少包括文件名、章节或块编号、版本号。系统不得伪造不存在的文档名称。若检索结果之间存在明显冲突，系统应提示冲突，不得自行把两个规则拼成新的制度。

7. 性能与可用性要求

普通问答的端到端响应目标为五秒以内，其中检索阶段目标不超过八百毫秒。上传文档后，知识管理员应能看到处理状态、生成块数量和失败原因。单个文件解析失败时，不得影响其他文件入库。

系统应记录请求时间、用户角色、查询文本哈希、检索文档标识、各阶段耗时和最终状态。日志不保存明文密码、访问令牌和未经批准的客户隐私字段。

8. 验收标准

首期验收使用人工标注测试集。检索部分至少报告 Recall@3、Recall@5、Recall@10、MRR 和平均检索时间。生成部分至少检查答案正确性、上下文忠实度、引用准确性和拒答合理性。

验收不以“能生成一段通顺文字”为标准。只有当检索证据正确、答案没有超出证据、权限过滤有效、失败情况可解释时，才视为通过。评测集、运行配置和原始结果必须保存，以便复现实验。

9. 变更原则

需求变更由产品负责人提出，知识管理员和安全负责人共同评审。涉及权限字段、日志内容、数据保留期限的修改必须经过安全评审。模型或向量模型升级不得直接覆盖旧基线，应使用独立配置运行对照实验。

10. 术语说明

RAG 指检索增强生成。Embedding 指把文本转换为向量表示。Document Store 指保存文档、向量和元数据的存储组件。Top K 指检索阶段返回的前 K 个候选块。Reranker 指对候选块进行二次排序的模型或算法。Faithfulness 指答案中的陈述是否能够由给定上下文支持。

11. 参考依据

本文为原创教学语料，业务组织和数据均为虚构。技术原则参考 Haystack 官方管线与检索器文档、Qdrant 官方搜索与过滤文档，以及 Lewis 等人提出的检索增强生成研究框架。