

星云知识助手文档接入与数据治理规范

文档编号: XY-RAG-DATA-002

版本: 1.1

发布日期: 2026-06-20

责任部门: 知识管理组

复审周期: 每六个月

1. 目的

本规范用于统一文档采集、清洗、分块、元数据、版本控制和下线流程。知识助手的回答质量首先取决于知识库质量。模型能力不能弥补错误文档、重复版本和缺失权限标签造成的问题。

2. 支持的文件类型

首期支持 UTF-8 编码的 TXT、可提取文本的 PDF 和结构清晰的 Markdown。扫描版 PDF 需要经过 OCR 后才能入库。包含复杂表格、双栏论文、页眉页脚和大量脚注的 PDF，应先进行人工抽查，因为直接抽取可能打乱阅读顺序。

单个文件建议小于二十兆字节。超过限制的文件应按自然章节拆分，不能按固定文件大小粗暴切割。拆分后的文件必须保留原始文档编号和章节关系。

3. 文档准入条件

允许入库的文档必须满足以下条件：有明确标题；有责任部门或作者；有版本号或发布日期；能判断当前状态；不存在明文密码、令牌或不必要的个人敏感信息；内容与业务范围相关。

草稿、聊天截图、无来源的网络摘抄和无法确认版本的文件默认不进入正式知识库。确需用于实验时，应标记 `environment=testing`，并与生产知识库隔离。

4. 文件命名规则

推荐格式为“部门_主题_版本_生效日期”。例如：

售后部_设备离线排查_v2.1_20260601.pdf

文件名只用于人工识别，不能作为唯一版本依据。系统元数据中的 `document_id`、`version` 和 `effective_date` 才是程序判断依据。

5. 文本清洗

清洗阶段删除重复页眉页脚、连续空行、乱码控制字符和无意义导航文字。章节标题、编号、警告语和表格行名应保留，因为这些结构有助于检索和回答。

不得为了“让文本更漂亮”而改写制度原文。清洗程序只能处理格式，不应改变数值、条件、否定词和责任主体。例如“不得直接重启”不能被清洗为“可以重启”。

6. OCR 处理

扫描件 OCR 后应抽查第一页、中间页和最后一页。涉及金额、日期、型号、故障码和百分比的内容需要重点检查。OCR 置信度过低的页面应标记 `review_required=true`，不直接进入正式索引。

图片中的流程图若无法可靠转成文字，应补充人工说明，说明中要写明“根据原图人工整理”。不能假装系统已经理解图形关系。

7. 分块策略

默认按自然段和标题优先分块，再限制最大长度。首期基线参数为 `chunk_size=450`、`chunk_overlap=80`。这里的长度由具体实现决定，必须在实验记录中说明是字符、词元还是其他单位。

分块时应避免把标题与正文完全分离，也应避免把一条完整的条件规则切成两块。重叠用于保留跨边界上下文，但重叠过大会造成重复检索和存储浪费。

对于短问答、错误码表和条款列表，可使用结构化分块。例如每个故障码一块，每条制度条款一块。对于长叙述文档，可按标题层级和段落组合。

8. 块级元数据

每个文档块至少包含：

`document_id`：文档唯一标识。

`source`：原始文件名。

`chunk_id`：文件内块编号。

title: 文档标题。

section: 章节路径。

version: 版本号。

effective_date: 生效日期。

status: draft、effective、expired 或 archived。

department: 责任部门。

access_level: 访问级别。

customer_scope: 适用客户范围。

checksum: 原文校验值。

元数据字段应使用稳定命名。不要今天写 dept，明天写 department。字段不一致会使过滤规则失效。

9. 版本控制

同一制度的新版本发布后，旧版本不应物理删除，而应标记 status=expired 或 archived。默认检索仅返回 status=effective 的内容。历史复盘需要旧版本时，必须由明确的时间范围或管理员权限触发。

若新版本只是排版变化、内容不变，可以复用逻辑版本，但仍应更新文件校验值。若任何规则、数值或适用范围改变，必须提升版本号并重新评测相关问题。

10. 重复与冲突处理

系统通过 document_id、版本、标题相似度和内容校验值识别重复。完全重复的文件不重复入库。部分重复但版本不同的文件可以保留，但必须正确标记状态。

发现同一生效期内的两个有效文档规则冲突时，应暂停自动发布并提交责任部门确认。系统不应依赖大语言模型自行裁决制度冲突。

11. 敏感信息处理

入库前必须移除访问令牌、密码、私钥、身份证号、个人手机号和未经批准的客户数据。脱敏后的案例可以保留故障现象、处理步骤和结果，但客户名称应替换为匿名标识。

权限标签必须来自可信业务系统或管理员选择，不能由模型根据内容猜测。误标为低密级比漏标更危险，因为它可能导致越权检索。

12. 入库流程

标准流程为：上传文件；文件类型校验；病毒和敏感信息检查；文本解析；格式清洗；分块；元数据补全；向量生成；写入测试集合；抽样检索；管理员确认；发布到正式集合。

任一步失败都应记录错误阶段和文件标识。失败文件不能显示为“已完成”。重新处理时应避免产生重复块。

13. 删除与下线

业务下线通常采用逻辑下线，将 `status` 改为 `archived`。只有出现法律要求、数据泄露或错误上传时才执行物理删除。物理删除后，应同步删除向量、缓存、临时文件和可恢复副本，并留下审计记录。

14. 数据质量检查

每次批量入库后至少检查：文件数量；成功和失败数量；平均块长度；过短块比例；重复块比例；缺失元数据比例；无向量块数量；抽样问题的检索结果。

块长度小于五十个字符通常需要人工检查，但标题、简短警告和故障码条目可以例外。异常阈值不能机械使用，应结合文档类型。

15. 备份与恢复

Qdrant 集合和原始文档均应有备份。恢复演练至少每季度一次。恢复后不仅要检查集合是否存在，还要运行固定问题集，确认向量维度、过滤字段和结果顺序没有异常。

16. 参考依据

本文为原创教学语料。分块、文档存储和检索组件设计参考 Haystack 官方文档；元数据过滤、向量检索和混合查询原则参考 Qdrant 官方文档。