

星云知识助手评测数据集与实验手册

文档编号: XY-RAG-EVAL-005

版本: 1.2

发布日期: 2026-06-28

责任部门: 算法评测组

1. 评测目标

评测用于回答三个问题: 系统是否找到正确证据; 系统是否依据证据正确作答; 改动是否真的优于基线。评测不能只展示几个成功案例, 也不能在看到结果后随意修改标准答案。

2. 测试集结构

每条样本至少包含 `id`、`question`、`question_type`、`gold_answer` 和 `relevant_documents`。`relevant_documents` 记录 `source` 与 `chunk_id`, 必要时增加 `section`。

推荐格式:

```
{
  "id": "Q001",
  "question": "离线故障首先检查什么?",
  "question_type": "procedure",
  "gold_answer": "先确认供电和网络连接, 再检查设备状态。",
  "relevant_documents": [
    {"source": "售后部_设备离线排查_v2.1.pdf", "chunk_id": 3}
  ]
}
```

标准答案用于说明关键信息, 不要求模型逐字一致。相关文档标注必须人工核对原文。

3. 问题类型

测试集至少覆盖五类问题。

事实类：答案通常位于一个块中，例如默认 Top K 是多少。

精确标识类：包含版本号、故障码、条款号等。

步骤类：需要完整保留顺序和前置条件。

多文档类：答案需要组合两个或更多来源。

不可回答类：知识库没有足够证据，系统应拒绝猜测。

每类问题数量不能过少。若全部都是简单事实题，Recall 很高也不能证明系统适合真实业务。

4. 标注流程

第一位标注者编写问题和相关块，第二位标注者独立复核。存在分歧时回到原文讨论，不以模型回答作为裁决依据。

问题应使用真实用户可能采用的表达，而不是完全复制文档句子。可以加入同义表达，但不得故意制造语法混乱来追求“困难”。

5. 检索指标

5.1 Recall@K

若前 K 个结果中包含至少一个相关块，则该问题命中。总体 Recall@K 是命中问题数除以问题总数。多相关块任务也可以计算找到的相关块比例，但必须说明采用哪种定义。

5.2 MRR

MRR 关注第一个相关块的排名。若第一个相关块排在第 1 位，该问题得分为 1；排在第 2 位得 1/2；没有出现得 0。最终取所有问题平均值。

5.3 Precision@K

Precision@K 表示前 K 个结果中相关块所占比例。对于每题只有一个相关块的测试集，K 增大时 Precision 往往下降，因此不能只看一个指标。

5.4 检索时间

记录从查询进入检索组件到返回候选的时间，不包括生成时间。建议同时报告平均值、P50 和 P95，避免少数慢请求被平均值掩盖。

6. 生成指标

答案正确性检查是否覆盖标准答案中的关键事实。忠实度检查答案陈述是否能由上下文支持。引用准确率检查引用是否真实存在且确实支持相关陈述。拒答合理性检查不可回答问题是否避免猜测。

自动指标可以提高效率，但正式结论仍需抽样人工复核。LLM 作为评审器时应固定评审模型和提示词，并保存原始评分理由。

7. 基线配置

首个基线固定为：

```
chunk_size=450  
chunk_overlap=80  
retriever=dense  
top_k=3  
score_threshold=关闭，仅用于离线评测  
embedding_model=BAAI/bge-small-zh-v1.5  
reranker=关闭  
generator=qwen2.5:3b  
temperature=0
```

基线的意义是提供可复现参照，不表示这些参数最佳。

8. 实验顺序

实验一比较分块长度和重叠，其他配置固定。实验二使用选定分块比较 Dense、BM25 和 Hybrid。实验三比较 Top K。实验四比较是否使用重排序。实验五比较 Embedding 模型。

不要一次改变多个主要变量，否则无法判断提升来自哪里。全部组合的暴力网格可能产生数百组实验，成本高且分析困难。

9. 分块实验

候选 chunk_size 为 256、512、1024，overlap 为 0、64、128。每组重新建立独立集合，避免旧块残留。记录块数量、平均块长度、索引时间、Recall@K、MRR 和检索时间。

分块效果必须结合问题类型分析。较小分块可能提高精确定位，但会丢失上下文；较大分块保留信息完整，却可能引入噪声。

10. 检索方法实验

Dense 适合语义改写，BM25 适合精确词项，Hybrid

试图结合两者。每种方法使用相同文档版本和问题集。融合方法、候选数量和权重必须记录。

若 Hybrid 提升总体 Recall，但降低故障码类精度，应报告这种差异，而不是只给总体平均值。

11. Top K 实验

比较 K=3、5、10。检索指标通常随 K 增大而提高，但生成效果未必同步提高，因为额外上下文可能包含噪声。应同时记录生成正确率、忠实度、提示词长度和延迟。

12. 重排序实验

先使用快速检索召回较多候选，再由重排序器选择前几名。报告重排前 Recall@20、重排后 MRR、最终 Precision@5 和增加的延迟。

若正确块不在候选中，重排序无能为力。发现此类失败时，应回到分块或召回方法，而不是继续调重排模型。

13. 结果文件

每次运行保存 config.json、per_query_results.jsonl、summary.json 和运行日志。文件夹命名示例：

```
results/2026-06-28_dense_k5_chunk512_overlap64/
```

per_query_results 至少包含问题

ID、返回块、分数、相关块排名和耗时。只保存汇总分数会失去错误分析能力。

14. 失败案例分析

将失败分为：相关文档未入库；相关信息被错误分块；查询与文本表达差异过大；精确标识被语义模型混淆；权限过滤过严；正确块已召回但排名低；生成忽略正确证据；知识库本身无答案。

每种类型至少选取若干案例写出修复建议。科研价值往往来自对失败原因的解释，而不是单一最高分。

15. 随机性与复现

固定随机种子，记录 Python、Haystack、Qdrant、模型和依赖版本。保存测试集快照和知识库文档校验值。运行环境变化后应重跑基线。

温度不为零时，生成评测至少重复多次并报告波动。检索通常更稳定，但近似索引和并发环境仍可能影响延迟。

16. 最低交付要求

第一版至少准备二十个问题，后续扩展到五十至一百个。必须有一个命令能完成检索评测并输出 Recall@3、Recall@5、Recall@10、MRR 和平均检索时间。

实验结论必须对应数据。例如只有当结果真实显示 Recall@5 从 0.72 提升到 0.84 时，才能在报告或简历中写该提升。

17. 参考依据

本文为原创教学语料。RAG 框架参考 Lewis 等人的研究；检索器与管线设计参考 Haystack 官方文档；混合查询与过滤参考 Qdrant 官方文档；忠实度和上下文精度概念参考 Ragas 官方文档。